

Deep learning based regression for optically inactive inland water quality parameter estimation using airborne hyperspectral imagery

作者: Chao Niu, Kun Tan, Xiuping Jia, Xue Wang

复现者: Zijun Lv

摘要

机载高光谱遥感具有空间和光谱分辨率高的特点, 为准确、高效地监测内陆水质提供了机会。许多研究侧重于评估和量化光学活性水质参数的浓度, 如叶绿素-a (Chla)、蓝藻和有色溶解有机物 (CDOM) 等参数。对于光学活性参数, 如高锰酸盐指数 (CODMn)、总氮 (TN)、总磷 (TP)、氨氮 (NH₃) 和氨氮 (NH₄)、氨氮 (NH₃-N) 和重金属等光活性参数, 很难直接估算其浓度, 传统的间接估算模型也无法满足其精度要求。传统的间接估算模型无法满足精度要求, 尤其是在污染严重的内陆水域。本研究在采集机载数据的同时, 在中国官河采集了 60 个 50 厘米深的水样。我们还开发并研究了两种基于深度学习的基于像素的深度神经网络回归模型 (pixelDNNR) 和基于斑块的深度神经网络回归模型 (patchDNNR) 来估算七个光学不活跃的水质参数。与偏最小二乘回归 (PLSR) 和支持向量回归 (SVR) 模型相比, 基于深度学习的回归模型能够获得更高的精度, 尤其是 patchDNNR 模型, 其对所有参数的预测精度都非常高, 预测数据集决定系数 (R_p^2) 和残差预测偏差 (RPD) 值分别大于 0.6 和 1.6。实验结果表明, 基于深度学习的回归模型在高维数据的特征提取和图像理解方面表现出了良好的性能, 为我们提供了一种用于非活动内陆水质参数估计的新方法。

关键词: 非光学特性水质参数; 机载高光谱图像; 基于深度学习的回归

1 引言

生态环境对社会经济的可持续发展至关重要。在此过程中, 水质问题成为迫切需要解决的核心难题。特别是点源和非点源污染导致的水质问题在内陆水体中尤为突出。然而, 传统的水质监测方法难以捕捉水质的时间和空间变化, 并消耗大量人力和时间。为了解决这一问题, 研究者们转向利用高光谱遥感数据, 这在内陆水质估算中展现出巨大潜力。相较于海洋和沿岸水质估算, 内陆水域通常涉及较小的区域, 因此高光谱遥感数据需要具备一定的空间分辨率才能进行准确估算。

以往的研究主要聚焦于光学活性参数的估算，例如叶绿素-a、蓝藻、CDOM 和总悬浮物等，这些参数能够较好地反映水质状况。然而，一些重要的水质参数，如总氮、总磷、氨氮、高锰酸盐指数以及重金属等，并不具备明显的光学活性，但对于水体富营养化和环境评估至关重要。因此，研究人员尝试通过间接相关性推断这些参数。尽管一些研究尝试利用机载高光谱数据估算这些非光学活性水质参数，但由于内陆水域光学环境的复杂性，传统的线性和非线性回归技术难以准确建模这种复杂的非线性关系。

随着人工智能的发展，机器学习方法成为了解决这一问题的新途径。偏最小二乘回归 (PLSR)、支持向量回归 (SVR) 等传统方法已经被应用于水质参数浓度的估算，但由于无法提取高光谱数据的深层光谱和空间特征，传统模型的精度受到限制。而基于深度学习的方法则具有提取高维数据特征的优势。深度神经网络 (DNN) 模型和卷积神经网络 (CNN) 模型相继被用于高光谱图像的分类和回归。这些深度学习模型相较于传统模型更能准确反映污染物的分布情况，且具有更高的预测精度。

2 相关工作

在此研究中，旨在利用机载高光谱图像进行内陆水域多项水质参数的估算，并考察深度学习模型在这一领域的应用潜力。研究者设计了两种基于深度学习的回归模型，通过端到端学习和非线性映射的方式，致力于解决光学非活性水质参数估算的挑战。这些模型不仅在高维数据特征提取方面呈现出显著优势，还提出了一种基于斑块的方法来有效捕捉空间光谱信息。本研究着眼于比较深度学习回归方法与传统回归方法（如 PLSR、SVR）在准确性上的区别，以探索新的高效水质估算策略。

2.1 光学活性水质参数

过去的研究多集中在测定水质中的光学活性参数，例如叶绿素-a (Chla) [9] [33]、蓝藻 [16] [23] [29]、CDOM [17] [19] 和总悬浮物 (TSM) [4] [18]。基于活性吸收和反射特性，研究人员利用半经验、半分析和生物光学模型建立了估算算法。半经验模型通过选择特定波段建立遥感数据与水质参数的关系，半分析模型则采用经验公式获取水质参数。生物光学模型则基于水辐射传递理论，关联表观光学特性 (AOPs) 和固有光学特性 (IOPs)，在水环境监测和估算方面取得良好效果 [8] [10] [12] [22]

2.2 非光学活性水质参数

除了这些光学活性水质参数外，还有一些重要的水质参数由于光学特性较弱而不具有光学活性。然而，这些光学不活跃参数，如总氮 (TN)、总磷 (TP)、氨氮 (NH₃-N)、高锰酸盐指数 (CODMn)、pH 值以及镉 (Cd)、镍 (Ni) 和锌 (Zn) 等重金属会受到光学活性参数的影响 [14] [31]。这些非光学活性水质参数与水体富营养化有关，对环境评估，尤其是人类健康具有重要意义。

然而，在内陆水域复杂的生物光学环境中，很难直接确定这些参数的光学特征 [1] [7]。不过，可以通过首先建立与光学活性参数的内部相关性，然后进行相关性分析来估算这些参数 [27] [28]。例如，TP 和 TN 可与 Chla 浓度直接相关，并与透明度或水透明度直接相关 [15] [30] [32]。悬浮固体通常是氮和磷的载体，两者通常高度相关 [5]。水中的重金属可以

以颗粒形式、溶解形式和生物形式存在 [34]。此外，重金属在水中的分布受悬浮沉积物、浮游植物和溶解有机物的控制，这意味着重金属的浓度与水的光谱特性相关 [3]。

3 本文方法

3.1 本文方法概述

本研究涉及了对 PLSR 线性回归方法和三种非线性回归方法的比较。这些非线性回归方法包括 SVR、以及基于深度学习的 pixelDNNR 和 patchDNNR 方法。

SVR 代表支持向量机 (SVM) 中的回归和函数逼近，在处理多维且小样本数据集时展现出其优越性 [20] [25]。其核心理念是在高维特征空间中寻找最佳逼近超平面，以估算 n 维输入向量和 1 维输出变量之间的线性相关性 [2]。

DNN 是一种前馈 ANN，具有多个隐藏层，其中输入层和输出层之间存在全连接 [24]。对于许多复杂的回归或分类问题，单个隐藏层无法解决，因此必须增加网络深度，设立多个隐藏层。多隐藏层网络结构能更好地表示数据，能够提取更深层次的特征，从而提高回归和分类的准确性，并能够从输入数据中学习模式。

在 DNN 中，多个隐藏层间存在大量连接神经元，这造成了高度冗余，同时也使得网络难以通过优化过程实现收敛 [6] [26]。为解决由多个隐藏层引发的梯度消失和梯度爆炸问题，我们引入了残差块。输入 x 通过捷径连接与非线性层的输出相连，最终输出为 $H(x)$ 。

3.2 基于像素点的网络结构

在我们的研究中，我们建立了一个包含七个隐藏层的 pixelDNNR 模型，采用 ReLU 作为激活函数。在批量归一化训练中，每个训练示例与小批量中的其他示例结合，这使得网络不再对特定训练示例产生确定的值，从而有利于网络的泛化效果 (Ioffe and Szegedy, 2015)。此外，Dropout 层随机忽略先前层的输出节点，在反向传播中，这意味着权重和偏置不会被更新，有助于提升深度学习模型的泛化能力，减少对训练数据集的过度拟合 (Srivastava 等人, 2014 年)。pixelDNNR 的网络结构图如图 1 所示。




图 1. pixelDNNR 网络结构图

3.3 基于块的网络结构

像素级深度神经网络聚焦于单个像素的信息，却忽略了图像的空间结构（Schwarz 等，2015）。相比之下，基于块的深度神经网络以图像的高度、宽度和深度为输入，更加重视空间信息，特别适用于高光谱图像处理。这类网络的核心是卷积层，它通过局部感知和权重共享有效地减少了参数数量和冗余（LeCun 和 Bengio，1995 年）。在处理多维图像像素时，输入块的大小会影响 patch-DNN 的特征表达。之前的研究发现，相对较小的输入块大小（ 8×8 ）更适合提取非线性空间特征，同时不会丢失异质信息（Pyo 等人，2019 年）。因此，在考虑图像分辨率和整体图像大小的情况下，我们优化了输入补丁大小，将其设置为 9×9 。patchDNNR 模型的网络结构包括三个卷积层、一个滤波层和三个全连接层。每个卷积层的步长为 1，第一个卷积层的滤波器大小为 3×3 ，其他卷积层的滤波器大小为 2×2 。所有层都使用了批量归一化和 ReLU 激活函数。patchDNNR 模型的网络结构如图 2 所示。




图 2. patchDNNR 网络结构图

3.4 原文数据集构建

原文的研究区域位于中国江苏省北部，涵盖了自西南向东北流淌的官河。官河是该省北部流入黄海的最大河流之一，属于天然潮汐河，全长约 77.5 公里，流域面积达 8000 平方公里。其年径流量大约为 35 亿立方米。官河地区不仅是重要的农业和渔业产区，还扮演着江苏省南部主要的工业转移通道之一的角色。

采样和飞行区域位于关河上游（ 34.22°N ， 119.54°E ）至河口（ 34.46°N ， 119.78°E ）的 36 公里范围内，如图 3 所示。根据《中国地表水环境质量标准》（GB3838-2002），关河的氮氮、总氮和氨氮均不同程度超标。污染源来自农业、生活和工业。官河周边有多个工业园区，对水质有不同程度的影响。另据报道，工业化工厂也对官河造成了污染，严重影响了官河水质，对当地水生生物构成了较高的环境风险 [11]。关河的水质还影响当地居民的健康和社会经济的可持续发展。

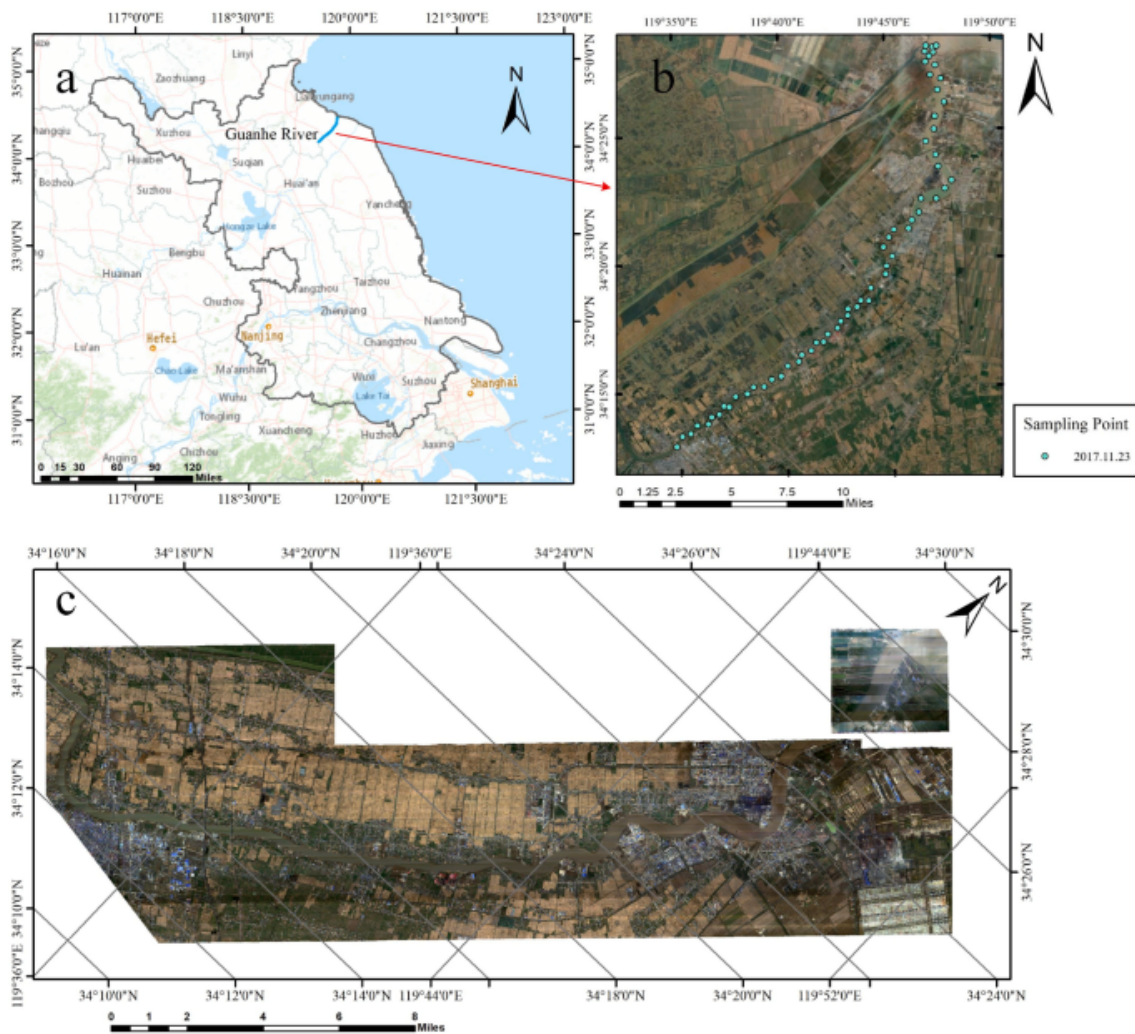


图 3. 原文研究区示意图

4 复现细节

4.1 与已有开源代码对比

此篇论文的代码和数据集未被公开分享, 鉴此, 本次实验复现了文献中提及的 pixelDNNR 和 patchDNNR 算法。为了验证这些算法在实际场景中的可行性, 本实验选择了广东省某城中村的河流作为研究区 (图 4)。通过运用无人机获取高光谱图像, 并运用近同步加密的技术, 采集了 40 个水体样本, 并构建了相应的数据集, 为本研究的实验提供了必要支持。




图 4. 本实验研究区示意图

4.2 实验环境搭建

本次实验中，使用了 PyTorch 框架，在 Intel(R) Core(TM) i7-12700 2.10 GHz 处理器上实现了算法的复现。训练阶段分别采用了 Adam 和 LBFGS 两种优化器来更新模型参数，学习率初始化设定为 0.01，同时采用了 30 的 batch size 进行了共计 150 个 epoch 的训练。

此外，由于使用了新的数据集，要对其高光谱图像进行预处理。这一处理过程包括根据采样点位置信息将高光谱图像分割成块，以满足 patchDNNR 模型的输入需求。鉴于本实验数据集图像的空间分辨率，我们将图像裁剪成了 32*32 大小的块。另外，在划分测试集和训练集时，我们特别考虑了数据分布的均衡性，以确保神经网络能够学习到尽可能多的特征信息。

4.3 使用说明

将采集所得的高光谱图像数据和采样点信息 excel 数据放入 src/dataset 文件夹下，运行 imagecrop.py 文件，该文件会将高光谱图像根据采样点信息中的坐标值裁剪为 32*32 大小的块，并保存至“src/dataset/32/对应水质参数名称”文件夹下。之后，进入 src/DNNRNet 文件夹下，这个文件夹包含的是网络结构文件和训练，测试文件。其中，DNNRNet.py 是基于块输入的网络结构，DNNRNetpoint.py 是基于像素点输入的网络结构。train.py 和 test.py 分别对应了 DNNRNet.py 的训练和测试文件；trainpoint.py 和 testpoint.py 对应了 DNNRNetpoint.py 的训练和测试文件。在运行训练和测试文件时，需要在各个文件的 argparse 中设置好参数，即可进行训练。

4.4 创新点

在本次实验的复现过程中，注意到所选用的模型在新数据集上的拟合效果较差。因此，我们在复现原文的基础上采取了一系列改进措施，包括修改损失函数（平滑的 L1 损失）和向原网络结构中引入通道注意力机制（SEBlock [13]）（图 5）。此外，针对原论文提出的基于像素和基于块输入的两网络结构，我们在新的数据集上进行了比较分析。

$$\text{Smooth}L_1 = \begin{cases} |x| - 0.5, & |x| > 1 \\ 0.5x^2, & |x| < 1 \end{cases} \quad (1)$$




图 5. SEBlock 示意图

除此之外，本实验还尝试使用了结合了自注意力与卷积优势的 ACMix [21] 模块（图 6），该模块思路为：卷积和自注意力机制的大部分计算代价来自于 1×1 卷积，因此通过 3 个 1×1 卷积对输入特征进行投影，然后 reshape 为 N 个 Pieces。之后分为自注意力机制和卷积核大小为 K 的路径分别进行操作。对于自注意力路径，将中间特征集合到 N 组中，每组包含 3 个特征，每个特征来自 1×1 卷积。对应的三个特征图分别作为 query、key 和 value，遵循传统的多头自注意力模块。对于卷积核大小为 k 的卷积路径，采用轻量级全连接层，生成特征映射。通过对生成的特征进行移位和聚合，对输入特征进行卷积处理，并像传统卷积一样从局部感受野收集信息。

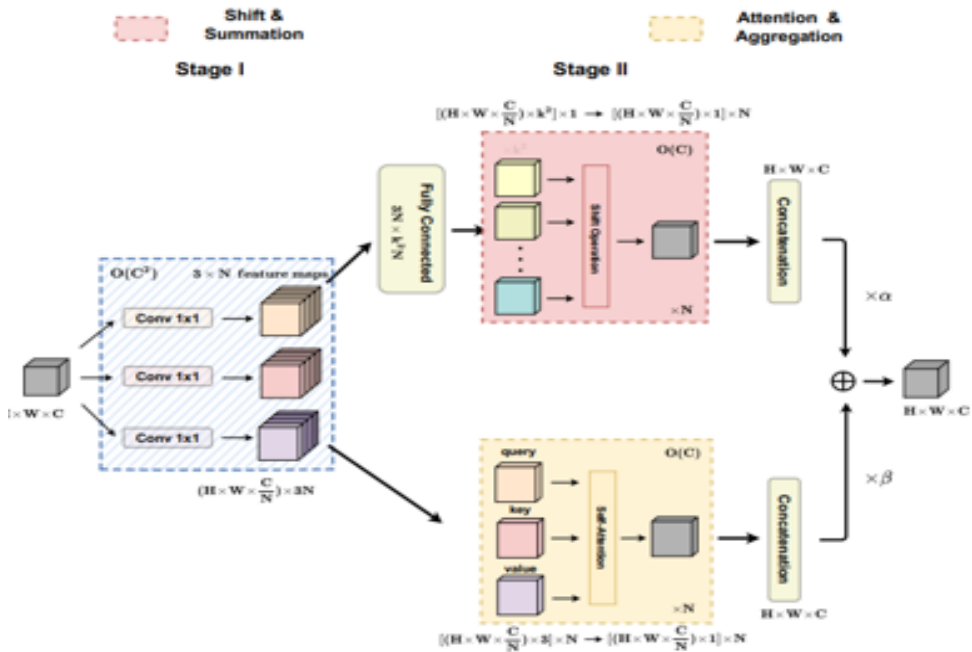


图 6. ACMix 示意图

在网络结构方面，本实验尝试使用 ConvNext [21] 来替换主干网络结构。ConvNext 通过重新审视卷积神经网络和 Transformer 之间的差距，对 ResNet 进行重新设计。它对 ResNet 的改进包括训练策略，还有引入金字塔结构、更改 block 比例等宏观设计（图 7）；还有替换与更改激活层、归一化层的类型和数量等微观设计，使得该网络结构取得了更好的效果。在训练策略方面，ConvNext 采用了 DeiT 论文中提出的增强版本的训练策略，包括数据增强、正则化、学习率调整等。在宏观设计方面，ConvNext 采用了金字塔结构，包含 4 个 stage，每个 stage 输出不同尺度的特征。ConvNext 调整了 ResNet-50 的每个 stage 的 block 的比例，最终得到的 block 数是 (3,3,9,3)。另外，它还采用了 ResNeXt 化，ConvNext 采用了 group conv 来提升性能，标准的 conv 其输入是所有的 channels，而 group conv 会对 channels 进行分组来减少计算量。

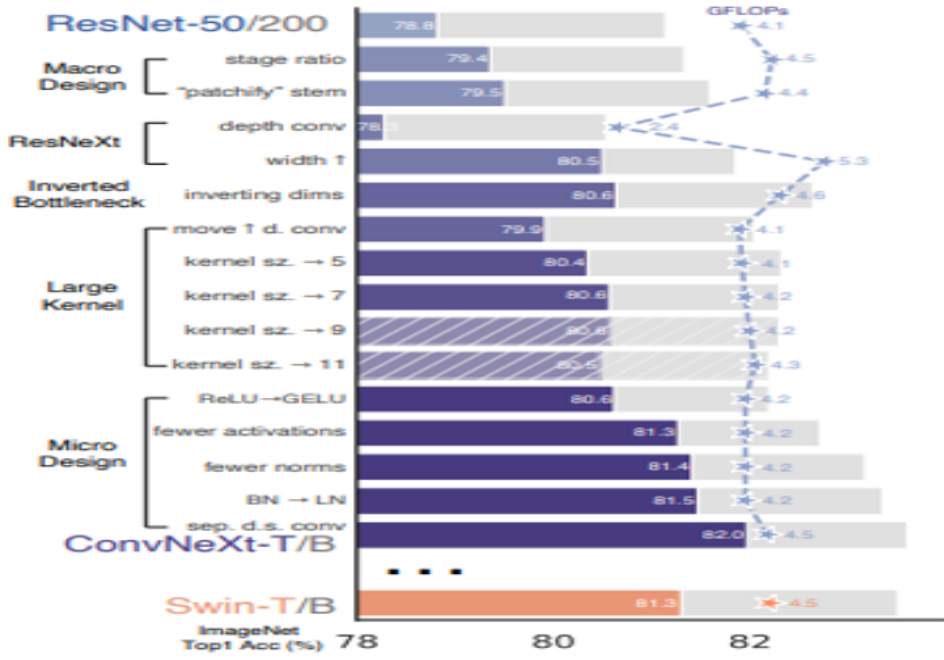


图 7. ConvNext 改进示意图

5 实验结果分析

在本次实验中，我们对几种不同的模型进行了比较：patchDNNR、pixelDNNR（图 8）、加入了通道注意力机制（SEBlock）的 patchDNNR、使用平滑 L1 损失函数的 patchDNNR、使用 ACMix 的 patchDNNR。我们观察了 MAE（平均绝对误差）、RMSE（均方根误差）和 R2（确定系数）这三种评价指标的变化趋势，从而分析了不同模型的性能表现。

结果显示，在处理高光谱图像时，采用块作为输入的模型相对于使用像素作为输入的模型表现更好，主要体现于结果更加稳定。这一结果与之前的研究观点相一致，表明块输入有助于更好地捕获高光谱图像的空间信息，并且能提高模型的稳定性。

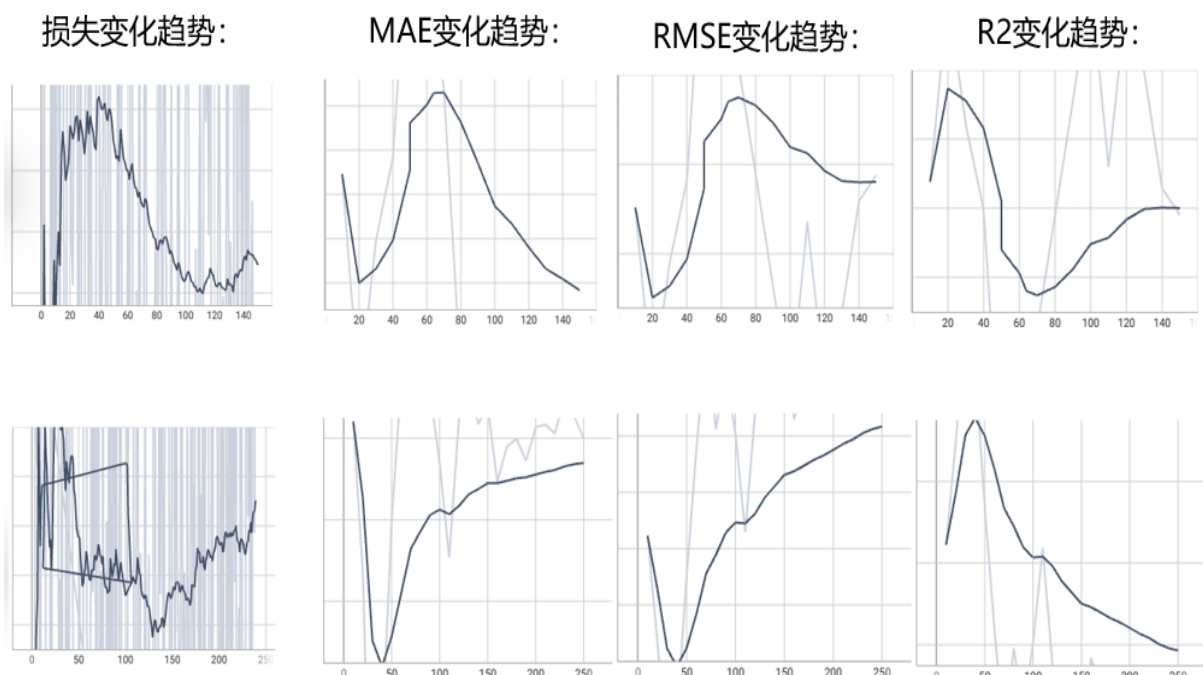


图 8. PatchDNNR 与 PixelDNNR 比较图（上方为 PatchDNNR 下方为 PixelDNNR）

鉴于高光谱图像的图像信息较多,我们在网络中引入了通道注意力机制(SEBlock、ACMix),它可以动态地学习并调整特征图中每个通道的重要性权重。结果显示,引入注意力机制可以提高模型的表征能力,增强模型对任务关键特征的抓取能力,这对于高光谱图像的处理是非常有益的。

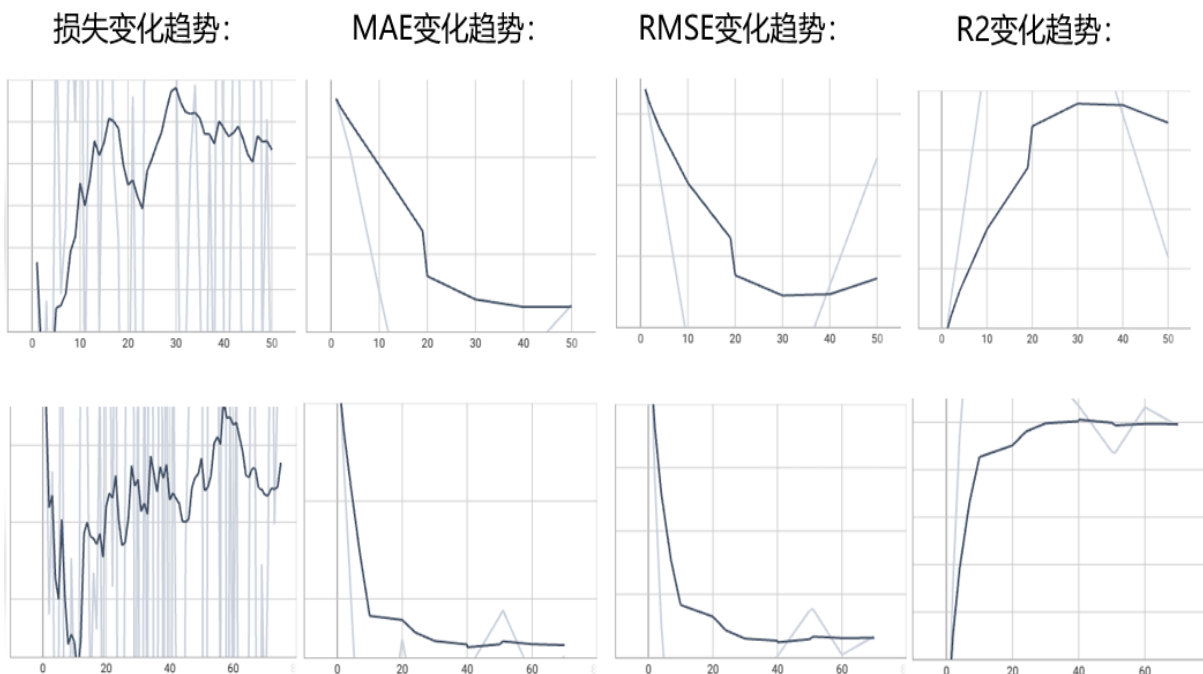


图 9. 加入注意力机制（上方为 SEBlock 下方为 ACMix）

此外,在采用平滑 L1 损失函数后,评价指标的变化趋势与使用 L1 损失函数时相似,但评价指标的数值有所改善。这表明了平滑 L1 损失函数对模型性能的提升作用,即使趋势相似,数值上的改进也是显著的。

损失变化趋势:

MAE变化趋势:

RMSE变化趋势:

R2变化趋势:

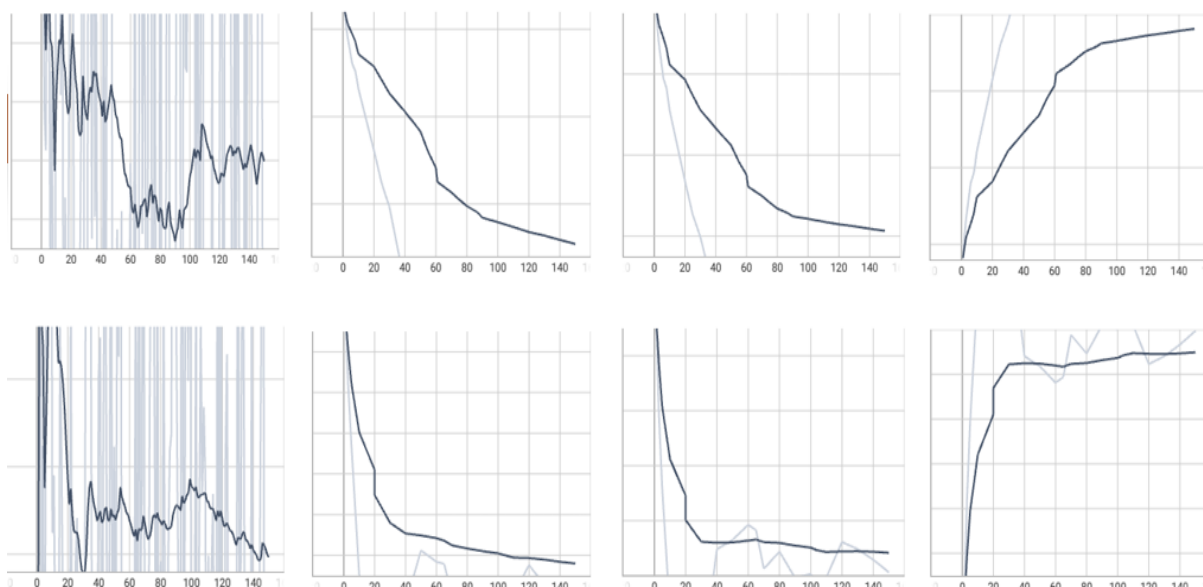


图 10. 更换损失函数与优化器 (上方为更换损失函数下方为更换优化器)

在更换网络结构为 ConvNext 后, 损失变化趋势与指标变化趋势对应, 且在训练集上 3 项指标都取得了良好效果。但是, 过拟合问题严重。因此该考虑解决过拟合问题, 由于 Dropout/-DropPath 在 ConvNext 网络结构中已经包含, 所以考虑从数据增强方面解决过拟合问题。

损失变化趋势:

MAE变化趋势:

RMSE变化趋势:

R2变化趋势:




图 11. 更换主干网络为 ConvNext

损失变化趋势:

MAE变化趋势:

RMSE变化趋势:

R2变化趋势:




图 12. 主干网络为 ConvNext 时, 采用选择策略进行数据增强

这些结果强调了不同策略在高光谱图像处理中的作用，块输入的优势、注意力机制的有效性以及使用平滑 L1 损失函数和波段相关性分析对模型性能的潜在提升，为高光谱图像处理领域提供了有益的参考和启示。

6 总结与展望

在这次实验中，探究了不同模型变体在处理高光谱图像时的性能差异。通过对比 patchDNNR、pixelDNNR、带有通道注意力机制的 patchDNNR 和使用平滑 L1 损失函数的 patchDNNR，我们观察了 MAE、RMSE、R2 等评价指标的变化趋势，并对结果进行了分析。

实验结果显示了几个发现：

首先是使用图像块进行输入，可以通过更多空间信息与上下文信息，降低数据的不平衡性以更好地利用数据。通过实验结果，使用 LBFGS 可以在中小型数据集获得较好结果，使得模型收敛速度提升。使用 SmoothMSE，可以增强模型的鲁棒性，获得更加稳定的训练。

其次，引入通道注意力机制（SEBlock [13]、ACMix [21]）使得模型能够动态地学习和调整特征图中通道和空间的重要性权重，从而提高了模型对关键特征的代表能力。特别是对于通道数目较多、空间尺度较大的高光谱图像，这种机制对模型性能的提升是显著的。

另外，通过实验结果，使用 LBFGS 可以在中小型数据集获得较好结果，使得模型收敛速度提升。使用 SmoothMSE，可以增强模型的鲁棒性，获得更加稳定的训练。

最后，更换主干网络为 ConvNext 效果显著提升但出现过拟合，这表现该网络结构具有更强大的特征提取能力，可以更好地拟合训练数据，从而提高了在训练集上的表现。这种提升可能源于网络更好地捕获了数据的复杂模式和特征。更强大的网络结构需要更多的数据来有效地泛化。如果训练数据量相对较小，新模型的表现可能在训练集上显著提升，但同时更容易过度拟合，因为模型过于依赖训练集中的特定样本或噪声。新的网络结构可能过于复杂，超出了训练数据所能支持的范围。这可能导致模型在训练集上过度学习，但在泛化到新数据时表现不佳。

总的来说，这次实验为高光谱图像处理提供了一系列有益的探索和启示。但鉴于时间短暂、设备限制等原因，没有对该模型进行更为细致的研究与比较。未来，可以进一步探究更多模型变体、不同的注意力机制以及更复杂的损失函数结构，以期进一步提高模型的性能和泛化能力。同时，可以考虑结合其他特征工程方法或深度学习技术，来进一步优化高光谱图像处理的模型，以满足不同应用场景下的需求。

参考文献

- [1] Karima Allali, Annick Bricaud, and Hervé Claustre. Spatial variations in the chlorophyll-specific absorption coefficients of phytoplankton and photosynthetically active pigments in the equatorial pacific. *Journal of Geophysical Research: Oceans*, 102(C6):12413–12423, 1997.
- [2] Richard G Brereton and Gavin R Lloyd. Support vector machines for classification and regression. *Analyst*, 135(2):230–267, 2010.

- [3] Chuqun Chen, Fenfen Liu, Qunjun He, and Heyin Shi. The possibility on estimation of concentration of heavy metals in coastal waters from remote sensing data. In *2010 IEEE International Geoscience and Remote Sensing Symposium*, pages 4216–4219. IEEE, 2010.
- [4] Arnold G Dekker, RJ Vos, and Steef WM Peters. Comparison of remote sensing data, model results and in situ data for total suspended matter (tsm) in the southern frisian lakes. *Science of the Total Environment*, 268(1-3):197–214, 2001.
- [5] Arnold G Dekker, RJ Vos, and SWM Peters. Analytical algorithms for lake water tsm estimation for retrospective analyses of tm and spot sensor data. *International journal of remote sensing*, 23(1):15–35, 2002.
- [6] A Di Noia, OP Hasekamp, G Van Harten, JHH Rietjens, JM Smit, F Snik, JS Henzing, J De Boer, CU Keller, and H Volten. Use of neural networks in ground-based aerosol retrievals from multi-angle spectropolarimetric observations. *Atmospheric Measurement Techniques*, 8(1):281–299, 2015.
- [7] Mohammad Haji Gholizadeh, Assefa M Melesse, and Lakshmi Reddi. A comprehensive review on water quality parameters estimation using remote sensing techniques. *Sensors*, 16(8):1298, 2016.
- [8] Anatoly A Gitelson, Giorgio Dall’Olmo, Wesley Moses, Donald C Rundquist, Tadd Barrow, Thomas R Fisher, Daniela Gurlin, and John Holz. A simple semi-analytical model for remote estimation of chlorophyll-a in turbid waters: Validation. *Remote Sensing of Environment*, 112(9):3582–3593, 2008.
- [9] Merzlyak M.N. Gitelson, A.A. Remote estimation of chlorophyll content in higher plant leaves. *International journal of remote sensing*, 18(12):2691–2697, 1997.
- [10] Howard R Gordon, Otis B Brown, Robert H Evans, James W Brown, Raymond C Smith, Karen S Baker, and Dennis K Clark. A semianalytic radiance model of ocean color. *Journal of Geophysical Research: Atmospheres*, 93(D9):10909–10924, 1988.
- [11] Zhao-Xiang Han, Lujian Lin, Yan Fan, and Cong Zou. Environmental risk assessment of the emerging edcs contaminants in guan river of jiangsu in china. *Acad J Sci Res*, 2018.
- [12] Pekka Härmä, Jenni Vepsäläinen, Tuula Hannonen, Timo Pyhälähti, Juha Kämäri, Kari Kallio, Karri Eloheimo, and Sampsa Koponen. Detection of water quality using simulated satellite data and semi-empirical algorithms in finland. *Science of the Total Environment*, 268(1-3):107–121, 2001.
- [13] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7132–7141, 2018.

- [14] D Kar, Pintu Sur, SK Mandai, T Saha, and RK Kole. Assessment of heavy metal pollution in surface water. *International Journal of Environmental Science & Technology*, 5:119–124, 2008.
- [15] T Kutser, H Arst, T Miller, L Käärman, and A Milius. Telespectrometrical estimation of water transparency, chlorophyll-a and total phosphorus concentration of lake peipsi. *International Journal of Remote Sensing*, 16(16):3069–3085, 1995.
- [16] Tiit Kutser. Quantitative detection of chlorophyll in cyanobacterial blooms by satellite remote sensing. *Limnology and Oceanography*, 49(6):2179–2189, 2004.
- [17] Tiit Kutser, Donald C Pierson, Kari Y Kallio, Anu Reinart, and Sebastian Sobek. Mapping lake cdom by satellite remote sensing. *Remote Sensing of Environment*, 94(4):535–540, 2005.
- [18] Shaohua Lei, Jie Xu, Yunmei Li, Chenggong Du, Ge Liu, Zhubin Zheng, Yifan Xu, Heng Lyu, Meng Mu, Song Miao, et al. An approach for retrieval of horizontal and vertical distribution of total suspended matter concentration from goci data over lake hongze. *Science of the Total Environment*, 700:134524, 2020.
- [19] Jiwei Li, Qian Yu, Yong Q Tian, and Brian L Becker. Remote sensing estimation of colored dissolved organic matter (cdom) in optically shallow waters. *ISPRS Journal of Photogrammetry and Remote Sensing*, 128:98–110, 2017.
- [20] Akpona Okujeni, Sebastian van der Linden, Laurent Tits, Ben Somers, and Patrick Hostert. Support vector regression and synthetically mixed training data for quantifying urban land cover. *Remote Sensing of Environment*, 137:184–197, 2013.
- [21] Xuran Pan, Chunjiang Ge, Rui Lu, Shiji Song, Guanfu Chen, Zeyi Huang, and Gao Huang. On the integration of self-attention and convolution. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 815–825, 2022.
- [22] J Penuelas, Frédéric Baret, and I Filella. Semi-empirical indices to assess carotenoid-s/chlorophyll a ratio from leaf spectral reflectance. *Photosynthetica*, 31(2):221–230, 1995.
- [23] Jong Cheol Pyo, Mayzonee Ligaray, Yong Sung Kwon, Myoung-Hwan Ahn, Kyunghyun Kim, Hyuk Lee, Taegu Kang, Seong Been Cho, Yongeun Park, and Kyung Hwa Cho. High-spatial resolution monitoring of phycocyanin and chlorophyll-a using airborne hyperspectral imagery. *Remote Sensing*, 10(8):1180, 2018.
- [24] Yao Qian, Yuchen Fan, Wenping Hu, and Frank K Soong. On the training aspects of deep neural network (dnn) for parametric tts synthesis. In *2014 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 3829–3833. IEEE, 2014.
- [25] Bernhard Schölkopf and Alexander J Smola. *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press, 2002.

- [26] Michal Segal-Rozenhaimer, Alan Li, Kamalika Das, and Ved Chirayath. Cloud detection algorithm for multi-modal satellite imagery using convolutional neural-networks (cnn). *Remote Sensing of Environment*, 237:111446, 2020.
- [27] Essam Sharaf El Din and Yun Zhang. Estimation of both optical and nonoptical surface water quality parameters using landsat 8 oli imagery and statistical techniques. *Journal of Applied Remote Sensing*, 11(4):046008–046008, 2017.
- [28] Essam Sharaf El Din, Yun Zhang, and Alaeldin Suliman. Mapping concentrations of surface water quality parameters using a novel remote sensing and artificial intelligence framework. *International Journal of Remote Sensing*, 38(4):1023–1042, 2017.
- [29] Stefan GH Simis, Steef WM Peters, and Herman J Gons. Remote sensing of the cyanobacterial pigment phycocyanin in turbid inland water. *Limnology and oceanography*, 50(1):237–245, 2005.
- [30] Kaishan Song, Lin Li, Shuai Li, Lenore Tedesco, Bob Hall, and Linhai Li. Hyperspectral remote sensing of total phosphorus (tp) in three central indiana water supply reservoirs. *Water, Air, & Soil Pollution*, 223:1481–1502, 2012.
- [31] Taleb Vakili and Jamil Amanollahi. Determination of optically inactive water quality variables using landsat 8 data: A case study in geshlagh reservoir affected by agricultural land use. *Journal of Cleaner Production*, 247:119134, 2020.
- [32] Jingzhe Wang, Tiezhu Shi, Danlin Yu, Dexiong Teng, Xiangyu Ge, Zipeng Zhang, Xiaodong Yang, Hanxi Wang, and Guofeng Wu. Ensemble machine-learning-based framework for estimating total nitrogen concentration in water using drone-borne hyperspectral imagery of emergent plants: A case study in an arid oasis, nw china. *Environmental Pollution*, 266:115412, 2020.
- [33] M Xu, Hongxing Liu, Richard Beck, John Lekki, Bo Yang, Song Shu, Yang Liu, Teresa Benko, Robert Anderson, Roger Tokars, et al. Regionally and locally adaptive models for retrieving chlorophyll-a concentration in inland waters from remotely sensed multispectral and hyperspectral imagery. *IEEE Transactions on Geoscience and Remote Sensing*, 57(7):4758–4774, 2019.
- [34] JL Zheng, ZD Wang, ZQ Lin, et al. A study of estuarine chemistry in the zhujiang river ii. chemical forms of heavy metals in the suspended particulate. *Oceanologia et Limnologia Sinica*, 13(6):523–530, 1982.